

Analyse de sentiments sur les critiques IMDB : Comparaison des embeddings TF-IDF, Word2Vec et BERT

Lucie Marimar Nouboussi Gnintedem
ENSAE Paris

luciemarimar.nouboussignintedem@ensae.fr

Mai 2025

Résumé

L'analyse de sentiments est une tâche clé en traitement automatique du langage, pour l'exploration d'opinions et l'analyse des retours clients. Cette étude évalue les performances de plusieurs modèles de classification sur le jeu de données ACL IMDB, en comparant les embeddings TF-IDF, Word2Vec et BERT.

Nous supposons que les embeddings contextuels de BERT surpasseront les représentations sparse et dense grâce à leur compréhension bidirectionnelle du texte. En utilisant Naive Bayes, Régression Logistique, SVM, XGBoost, ElasticNet et un classificateur basé sur BERT, nous obtenons des précisions allant jusqu'à 0,89 avec BERT, dépassant TF-IDF (0,88) et Word2Vec (0,81).

Nos résultats soulignent la supériorité des grands modèles de langage, malgré leur complexité computationnelle. Nous discutons des limites et proposons des directions futures pour optimiser les embeddings.

1 Introduction

L'analyse de sentiments, qui consiste à classer un texte comme positif ou négatif, est une tâche fondamentale en traitement automatique du langage (TAL) avec des applications dans la surveillance des médias sociaux, les critiques de produits et l'analyse des retours clients [Pang and Lee, 2008]. Le jeu de données ACL IMDB, introduit par Maas et al. [2011], est une référence pour la classification binaire des sentiments, comprenant 50 000 critiques de films (25 000 pour l'entraînement, 25 000 pour le test) réparties équitablement entre sentiments positif et négatif.

Cette étude compare trois méthodes de représentation des mots : TF-IDF, Word2Vec et BERT, pour la classification des sentiments, en évaluant leur impact sur les performances des modèles. Nous supposons que BERT, un modèle de transformeur bidirectionnel, surpassera les embeddings traditionnels grâce à sa capacité à capturer les relations contextuelles. Nos expériences utilisent divers classificateurs (Naive Bayes, Régression Logistique, SVM, XGBoost, ElasticNet et BERT) et évaluent les performances à l'aide de la précision, du F1-score, de la précision, du rappel et des courbes ROC.

2 Petite revue de la littérature

L'analyse de sentiments a connu des avancées majeures avec l'évolution des techniques de TAL. Les approches initiales utilisaient des modèles de sac de mots et TF-IDF, offrant des performances acceptables mais ignorant l'ordre des mots [Pang et al., 2002]. Les embeddings de mots comme Word2Vec [Mikolov et al., 2013] ont introduit des représentations denses capturant les relations sémantiques, mais elles manquent de contexte global. Les modèles de transformeurs, notamment BERT [Devlin et al., 2018], ont révolutionné le TAL grâce à leur pré-entraînement sur de vastes corpus et leur capacité à modéliser le contexte bidirectionnel.

BERT atteint des précisions de 0,90–0,93 sur IMDB dans des études récentes [Sun et al., 2019, Liu et al., 2019]. D'autres modèles comme RoBERTa et DistilBERT ont amélioré l'efficacité et les performances [Liu et al., 2019, Sanh et al., 2019]. Les approches non basées sur les transformeurs, telles que les réseaux convolutifs (CNN) [Kim, 2014], restent utilisées mais sont généralement surpassées par les transformeurs sur de grands jeux de données.

Notre travail compare les embeddings traditionnels et modernes pour évaluer leurs avantages et limites dans l'analyse de sentiments.

3 Description des données

Le jeu de données ACL IMDB contient 50 000 critiques de films, divisées en 25 000 échantillons d'entraînement et 25 000 de test, avec un équilibre parfait entre critiques positives et négatives (50 % chacune). Les données ont été récupérées

depuis <https://ai.stanford.edu/~amaas/data/sentiment/> et prétraitées à l'aide d'expressions régulières pour supprimer les balises HTML, la ponctuation et les caractères non alphabétiques. Une lemmatisation a été appliquée via spaCy pour normaliser les mots.

L'analyse statistique montre une longueur moyenne des critiques de 234 mots (écart-type : 173), les critiques positives étant légèrement plus longues (moyenne : 239) que les négatives (moyenne : 234). Le vocabulaire après prétraitement comprend environ 99 420 tokens uniques. La Figure 1 illustre la distribution des longueurs des critiques, révélant une distribution asymétrique à droite, avec la plupart des critiques sous 500 mots.




FIGURE 1 – Distribution de longueur des critiques

Les nuages (Figure 2) de mots montrent les termes les plus fréquents dans les critiques de films négatives et positives. Dans les critiques négatives, les mots dominants comme cinema, mind, war, student ou teacher traduisent une approche plus analytique, souvent centrée sur des aspects critiques ou techniques du film. On y perçoit une certaine distance ou insatisfaction. Par contre, les critiques positives mettent en avant des mots comme understand, shine, effect, camera ou dream, soulignant une appréciation de l'expérience esthétique, émotionnelle et narrative. Cette opposition montre que les critiques négatives se concentrent davantage sur le fond et les limites perçues du film, tandis que les critiques positives valorisent l'impact sensoriel, artistique et émotionnel de l'œuvre.




FIGURE 2 – Nuage de mots les plus fréquents dans les données d’entraînement

Dans les critiques négatives (Figure 3), on remarque une présence importante de mots factuels et descriptifs tels que *through*, *films*, *scenes*, *actors*, *director*, ou encore *worst*, ce dernier traduisant explicitement un jugement négatif. D'autres mots comme *didn't*, *doesn't*, *actually* et *still* peuvent également refléter une insatisfaction ou une réserve. En revanche, dans les critiques positives, bien que certains mots soient neutres ou partagés (*scene*, *back*, *such*, *through*), on observe aussi des termes à connotation valorisante tels que *better*, *real*, *makes*, *plot*, *work* ou *acting*. L'usage fréquent de mots partagés dans les deux types de critiques indique aussi que le contexte et l'orientation sémantique globale déterminent la tonalité, plus que les mots eux-mêmes.




FIGURE 3 – Mots les plus fréquents dans le jeu d'entraînement

4 Méthodologie

Nous proposons d'évaluer l'impact des méthodes de représentation des mots sur les performances de classification des sentiments. L'hypothèse est que les embeddings contextuels de BERT surpasseront TF-IDF (sparse) et Word2Vec (dense mais non contextuel) en raison de leur capacité à modéliser les relations bidirectionnelles. Nous justifions l'utilisation de plusieurs classificateurs pour évaluer la robustesse :

- **TF-IDF** : Une référence pour les représentations sparse, efficace pour les modèles linéaires.
- **Word2Vec** : Capture les relations sémantiques, adapté aux entrées vectorielles denses.
- **BERT** : Un modèle de transformeur de pointe pour les embeddings contextuels.

Les classificateurs incluent Naive Bayes, Régression Logistique, SVM, XGBoost, ElasticNet et un modèle BERT affiné. Les hyperparamètres sont réglés via GridSearchCV pour les modèles traditionnels, tandis que BERT est affiné avec un taux d'apprentissage de $2e-5$ sur 3 époques. Les performances sont évaluées avec la précision, le F1-score, la précision, le rappel et l'AUC ROC, la **précision** étant la métrique principale en raison de l'**équilibre des classes**.

5 Expériences

Il a été implémenté le pipeline suivant :

1. **Prétraitement** : Nettoyage des critiques et lemmatisation.
2. **Embedding** : Génération de vecteurs TF-IDF, d'embeddings Word2Vec (taille : 100–200, fenêtre : 5–10) et d'encodages BERT (longueur max : 128).
3. **Classification** : Entraînement des modèles avec scikit-learn pour les classificateurs traditionnels et PyTorch pour BERT. GridSearchCV a été utilisé pour le réglage des hyperparamètres.
4. **Évaluation** : Calcul des métriques sur les ensembles d'entraînement et de test, avec des courbes ROC.

6 Résultats

6.1 Résultats avec TF-IDF

Les résultats des modèles avec TF-IDF (Table 6.1) montrent qu'ElasticNet domine avec une précision de 0,9411 sur l'ensemble d'entraînement et 0,8784 sur le test, suivi de près par SVM (0,8962 et 0,8684). Ces modèles linéaires excellent grâce à leur robustesse aux représentations sparse, offrant un bon équilibre entre précision et rappel. Naive Bayes et XGBoost, bien que performants sur l'entraînement (0,9058 et 0,9128), souffrent d'un surajustement (overfit), avec des précisions test de 0,8247 et 0,8358, respectivement.

Modèle	Ensemble d'entraînement				Ensemble de test			
	Précision	Précision (P)	Rappel (R)	F1-score	Précision	Précision (P)	Rappel (R)	F1-score
Naive Bayes	0.9058	0.9221	0.8865	0.9039	0.8247	0.8679	0.7661	0.8138
Régression Logistique	0.8736	0.8554	0.8993	0.8768	0.8527	0.8379	0.8745	0.8558
SVM	0.8962	0.8785	0.9195	0.8985	0.8684	0.8515	0.8924	0.8715
XGBoost	0.9128	0.8884	0.9442	0.9155	0.8358	0.8188	0.8626	0.8401
ElasticNet	0.9411	0.9364	0.9465	0.9414	0.8784	0.8791	0.8776	0.8783

TABLE 1 – Performances des modèles avec TF-IDF sur les ensembles d'entraînement et de test.

Sur l'ensemble d'entraînement (Figure 4), toutes les courbes ROC montrent des AUC élevées (proches de 1), avec ElasticNet (AUC = 0.98) et XGBoost (AUC = 0.98) dominant, suivis de SVM (AUC = 0.96) et Régression Logistique (AUC = 0.95), ET Naive Bayes (AUC = 0.97). ElasticNet et XGBoost capturant efficacement les patterns. Sur l'ensemble de test (Figure 4), les AUC diminuent, indiquant un léger surajustement : ElasticNet conserve la meilleure performance (AUC = 0.95), suivi de SVM (AUC = 0.94), Régression Logistique (AUC = 0.93), XGBoost (AUC = 0.92), et Naive Bayes (AUC = 0.91). La baisse est notable pour XGBoost et Naive Bayes, confirmant une généralisation moins robuste, tandis qu'ElasticNet et SVM maintiennent une bonne capacité discriminative. Ces résultats corroborent les métriques précédentes, soulignant la robustesse d'ElasticNet et SVM avec TF-IDF.




FIGURE 4 – Courbes ROC pour TF-IDF

6.2 Résultats avec Word2Vec

Le tableau 6.2 montre que les performances avec Word2Vec sont globalement inférieures à celles obtenues avec TF-IDF. Sur l'ensemble d'entraînement, XGBoost domine avec une précision de 0,8852 et un F1-score de 0,8862, suivi de SVM (0,8402

et 0,8418), tandis que Naive Bayes sous-performe nettement (0,7104 et 0,7070), probablement en raison de son hypothèse d'indépendance des caractéristiques, inadaptée aux embeddings denses. Sur le test, SVM et ElasticNet affichent les meilleures précisions (0,8304 et 0,8270), avec des F1-scores équilibrés (0,8312 et 0,8274), mais XGBoost chute à 0,8082, indiquant un surajustement marqué. Comparé à TF-IDF (précision test ElasticNet : 0,8784), Word2Vec capture moins bien les relations sémantiques dans ce contexte, peut-être en raison d'un réglage sous-optimal des hyperparamètres (taille des vecteurs, fenêtre), suggérant qu'une optimisation ou des embeddings contextuels comme BERT (précision test : 0,89) seraient plus adaptés. Les

Modèle	Ensemble d'entraînement				Ensemble de test			
	Précision	Précision (P)	Rappel (R)	F1-score	Précision	Précision (P)	Rappel (R)	F1-score
Naive Bayes	0.7104	0.7156	0.6986	0.7070	0.7035	0.7164	0.6736	0.6943
Régression Logistique	0.8304	0.8267	0.8360	0.8313	0.8261	0.8246	0.8285	0.8265
SVM	0.8402	0.8336	0.8502	0.8418	0.8304	0.8272	0.8351	0.8312
XGBoost	0.8852	0.8790	0.8934	0.8862	0.8082	0.8072	0.8098	0.8085
ElasticNet	0.8308	0.8268	0.8370	0.8319	0.8270	0.8253	0.8296	0.8274

TABLE 2 – Performances des modèles avec Word2Vec sur les ensembles d'entraînement et de test.

courbes ROC des modèles avec Word2Vec (Figure 5) montrent des performances stables entre les ensembles d'entraînement et de test. Sur l'ensemble d'entraînement, XGBoost atteint le meilleur AUC (0,95), suivi de SVM (0,92), Régression Logistique et ElasticNet (0,91 chacun), tandis que Naive Bayes est en retrait avec 0,78, reflétant une capacité discriminative limitée due à son hypothèse d'indépendance inadaptée aux embeddings denses. Sur l'ensemble de test, les AUC restent proches : SVM, Régression Logistique et ElasticNet maintiennent un solide 0,91, XGBoost baisse légèrement à 0,89, et Naive Bayes reste à 0,77. Cette stabilité certifie une généralisation correcte pour les modèles linéaires (SVM, ElasticNet), bien que leurs AUC soient inférieures à celles de TF-IDF (0,95 pour ElasticNet). Naive Bayes sous-performe constamment, tandis que la baisse modérée de XGBoost (0,95 à 0,89) met en lumière un surajustement.




FIGURE 5 – Courbes ROC pour Word2Vec

6.3 BERT

Le Tableau 6.3 montre que BERT excelle sur l'ensemble d'entraînement avec une précision de 0,9944 et un F1-score de 0,9943, reflétant une bonne capacité à discriminer les sentiments grâce à ses embeddings contextuels. Cependant, sur l'ensemble de test, la précision chute à 0,8908 et le F1-score à 0,8879, indiquant un grand overfitting. La précision test (0,9115) reste élevée, mais le rappel (0,8656) montre que BERT manque quelques critiques positives, ce qui est cohérent avec sa performance légèrement inférieure à celle rapportée dans la revue de littérature (jusqu'à 0,93). Comparé à TF-IDF (ElasticNet : 0,8784) et Word2Vec (SVM : 0,8304), BERT surpasse ces approches, confirmant l'avantage des transformeurs, bien que des ajustements (par exemple, plus d'époques ou une régularisation) pourraient optimiser sa généralisation. L'AUC test de 0,89 est cohérente avec le F1-score

Ensemble	Précision	Précision (P)	Rappel (R)	F1-score
Entraînement	0.9944	0.9973	0.9914	0.9943
Test	0.8908	0.9115	0.8656	0.8879

TABLE 3 – Performances du modèle BERT sur les ensembles d’entraînement et de test.

de 0,8879, mais la précision (0,9115) et le rappel (0,8656) montrent que BERT excelle dans l’identification des positifs tout en manquant quelques cas. Comparaison avec TF-IDF et Word2Vec : L’AUC test de 0,89 est inférieur à TF-IDF (0,95) et Word2Vec (0,91), indiquant que BERT ne tire pas pleinement parti de ses capacités contextuelles dans cette configuration, possiblement en raison d’un surapprentissage ou d’un réglage suboptimal.




FIGURE 6 – Courbe ROC pour BERT

7 Discussion et Conclusion

Les résultats obtenus dans cette étude révèlent des performances variées selon les méthodes de représentation des mots et les modèles appliqués à l’analyse de sentiments sur le jeu de données ACL IMDB. Les embeddings TF-IDF, avec ElasticNet atteignant une précision de 0,8784 et un AUC de 0,95 sur l’ensemble de test (grâce à gridsearch et la cross validation), démontrent une robustesse remarquable, capturant efficacement les signaux de sentiment grâce à leur nature sparse et leur simplicité computationnelle. Word2Vec, bien que capturant des relations sémantiques avec SVM (précision : 0,8304, AUC : 0,91), sous-performe légèrement, probablement en raison d’un réglage suboptimal des hyperparamètres comme la taille des vecteurs ou la fenêtre, ce qui limite sa généralisation. BERT, malgré une performance impressionnante sur l’entraînement (précision : 0,9944, AUC : 0,99), montre un surajustement significatif avec une précision test de 0,8908 et un AUC de 0,89, inférieur à TF-IDF et Word2Vec, suggérant que son potentiel contextuel n’est pas pleinement exploité dans cette configuration, peut-être en raison d’un nombre d’époques ou d’une régularisation insuffisante. Le cout en terme de temps et de puissance d’ordinateur empêche d’explorer en profondeur, et de les tester.

La stabilité des modèles linéaires (ElasticNet, SVM) par rapport à XGBoost (surajustement avec TF-IDF et Word2Vec) et à BERT met en évidence l’importance d’une régularisation adaptée, surtout avec des données complexes.

Les **limites** incluent le surajustement des modèles complexes, l’équilibre des classes qui ne reflète pas les scénarios réels, et la possible dépendance des performances de TF-IDF à la clarté des mots discriminants dans IMDB. Des ajustements, comme l’optimisation des hyperparamètres pour Word2Vec ou une distillation pour BERT, pourraient améliorer les résultats, tandis que tester sur des données déséquilibrées offrirait une évaluation plus réaliste.

Références

- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert : Pre-training of deep bidirectional transformers for language understanding. *arXiv preprint arXiv :1810.04805*, 2018.
- Yoon Kim. Convolutional neural networks for sentence classification. *arXiv preprint arXiv :1408.5882*, 2014.
- Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Mandar Joshi, Danqi Chen, Omer Levy, Mike Lewis, Luke Zettlemoyer, and Veselin Stoyanov. Roberta : A robustly optimized bert pretraining approach. *arXiv preprint arXiv :1907.11692*, 2019.
- Andrew L Maas, Raymond E Daly, Peter T Pham, Dan Huang, Andrew Y Ng, and Christopher Potts. Learning word vectors for sentiment analysis. *Proceedings of the 49th Annual Meeting of the Association for Computational Linguistics*, pages 142–150, 2011.
- Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient estimation of word representations in vector space. *arXiv preprint arXiv :1301.3781*, 2013.
- Bo Pang and Lillian Lee. Opinion mining and sentiment analysis. *Foundations and Trends in Information Retrieval*, 2(1-2) :1–135, 2008.
- Bo Pang, Lillian Lee, and Shivakumar Vaithyanathan. Thumbs up ? sentiment classification using machine learning techniques. *Proceedings of the ACL Conference on Empirical Methods in NLP*, pages 79–86, 2002.
- Victor Sanh, Lysandre Debut, Julien Chaumond, and Thomas Wolf. Distilbert, a distilled version of bert : smaller, faster, cheaper and lighter. *arXiv preprint arXiv :1910.01108*, 2019.
- Chi Sun, Xipeng Qiu, Yige Xu, and Xuanjing Huang. How to fine-tune bert for text classification ? *arXiv preprint arXiv :1905.05583*, 2019.